

Clasificación de señales EEG de imaginación motora mediante métodos clásicos y modelos híbridos de aprendizaje profundo: comparación entre CSP+SVM, CNN y CNN-LSTM

M. Quistial

1. Contexto de aplicación

La clasificación de señales electroencefalográficas (EEG) durante tareas de *imaginación motora* (MI) constituye un pilar esencial en el desarrollo de interfaces cerebro-computador (BCI) no invasivas, orientadas a rehabilitación y control de dispositivos externos. Durante la imaginación kinestésica (KMI), las oscilaciones sensorimotoras en las bandas μ (8-12 Hz) y β (13-30 Hz) se modulan de manera similar a la ejecución real de movimientos, produciendo fenómenos de desincronización y resincronización relacionados con eventos (ERD/ERS) [1, 2].

Los estudios clásicos basados en *Common Spatial Patterns* (CSP) y clasificadores como *Support Vector Machines* (SVM) o *Linear Discriminant Analysis* (LDA) han logrado precisiones cercanas al 90 % en paradigmas binarios, pero dependen de calibraciones por sujeto y de la ingeniería manual de características [6].

Por el contrario, los modelos de *Deep Learning* (DL), especialmente las *Redes Neuronales Convolucionales* (CNN) y las *Long Short-Term Memory* (LSTM), permiten aprender representaciones espacio-temporales directamente a partir de los datos EEG [3]. La combinación de ambas en arquitecturas híbridas CNN-LSTM ha demostrado un desempeño superior, al capturar simultáneamente la correlación espacial entre electrodos y la dinámica temporal de los ritmos corticales [7, 8].

Zhang *et al.* (2023) caracterizaron las diferencias entre imaginaciones kinestésicas simples (S-KMI) y dobles (D-KMI) en personas diestras, demostrando que la KMI con una sola mano genera patrones ERD/ERS más marcados y mayor lateralización hemisférica [2]. Este hallazgo respalda el uso de paradigmas S-KMI en tareas de clasificación binaria de imaginación motora.

Además, Kim *et al.* (2025) reportaron que los sistemas híbridos basados en CNN que combinan señales de MI y potenciales somatosensoriales (SSSEP) logran una mejora del 64 % en precisión, incluso con electrodos secos [5]. Wang *et al.* (2025) desarrollaron la red IFNet, que superó en un 27 % a FBCSP en control continuo online [9]. De manera complementaria, Gwon y Ahn (2024) propusieron un modelo de *transfer learning* entre ejecución, observación e imaginación motora, incrementando la robustez intersujeto [4].

2. Objetivo de aprendizaje automático

El objetivo principal es predecir la clase de tarea motora imaginada (mano izquierda o derecha) a partir de señales EEG multicanal preprocesadas. Dadas las matrices $X \in \mathbb{R}^{C \times T}$, con $C = 64$ canales y T muestras temporales, se busca estimar una etiqueta $y \in \{\text{MI-L}, \text{MI-R}\}$.

Los modelos evaluados serán:

- **CSP+SVM:** extracción de características espaciales discriminantes y clasificación con SVM lineal o RBF.
- **CNN:** red convolucional profunda para el aprendizaje directo de patrones espaciales y frecuenciales.
- **CNN-LSTM:** arquitectura híbrida que combina la capacidad convolucional para representar información espacial y la recurrente para modelar secuencias temporales, mejorando la generalización intersujeto [3, 7].

3. Dataset

El conjunto de datos proviene de 15 sujetos sanos, registrados mediante un sistema de 64 electrodos (configuración 10-20 internacional) a 128 Hz. Cada sujeto realizó 22 ensayos de 9 s (-3 a +6 s) alternando entre MI-L y MI-R, totalizando 660 ensayos balanceados. El preprocesamiento incluyó filtrado pasabanda (8-30 Hz), eliminación de artefactos mediante Análisis de Componentes Independientes (ICA) y normalización canal a canal. Cada ensayo se representó como una matriz 64×1152 , ocupando aproximadamente 1.2 GB. Este protocolo es coherente con los utilizados por Borra *et al.* (2025) y Rimbert & Fleck (2023), quienes validaron la consistencia de paradigmas KMI con períodos de fijación y tareas motoras alternadas [1, 3].

4. Métricas de desempeño

Las métricas utilizadas son las convencionales en decodificación EEG:

- **Exactitud (Accuracy):** proporción de clasificaciones correctas.
- **Precisión (Precision) y Exhaustividad (Recall):** control de falsos positivos y negativos.
- **F1-score:** balance entre precisión y recall.
- **Cohen's κ :** concordancia ajustada por azar.

Rangos esperados:

- CSP+SVM: 85-95 % [6].
- CNN: 90-97 % [5, 9].
- CNN-LSTM: 94-99 % [7, 8].

5. Referencias y resultados previos

Los resultados reportados en la literatura coinciden en la superioridad de los modelos híbridos CNN-LSTM sobre los métodos clásicos. Dharmendra *et al.* [7] alcanzaron precisiones del 96 % con CNN-LSTM y GRU. Borra *et al.* [3] establecieron un protocolo reproducible de decodificación EEG en 204 participantes. Zhang *et al.* [2] demostraron que la imaginación kinestésica con una sola mano (S-KMI) genera lateralización más clara que la doble (D-KMI), optimizando la discriminación hemisférica en personas diestras. Gwon y Ahn [4] implementaron un modelo de transferencia entre ejecución y MI, reduciendo el tiempo de calibración. Kim *et al.* [5] mostraron la viabilidad de sistemas híbridos CNN para MI-SSSEP. Finalmente, Rimbart y Fleck [1] destacaron la importancia de la práctica prolongada en la estabilización de los patrones ERD/ERS.

En conjunto, estos hallazgos respaldan la adopción de modelos híbridos CNN-LSTM para la clasificación MI-EEG, integrando paradigmas kinestésicos S-KMI y estructuras de aprendizaje profundo adaptativas, capaces de mejorar la robustez, la eficiencia y la aplicabilidad clínica de los sistemas BCI.

Referencias

- [1] S. Rimbart and S. Fleck, “Long-term kinesthetic motor imagery practice with a BCI: Impacts on user experience, motor cortex oscillations and BCI performances,” *Computers in Human Behavior*, vol. 146, p. 107789, 2023.
- [2] Z. Zhang, P. Li, A. Connelly, P. Rangpong, and T. Yagi, “Characterization of kinesthetic motor imageries for right-handed people,” in *Proc. IEEE BMEiCON*, pp. 1–7, 2023.
- [3] D. Borra, E. Magosso, and M. Ravanelli, “A protocol for trustworthy EEG decoding with neural networks,” *Neural Networks*, vol. 182, 106847, 2025.
- [4] D. Gwon and M. Ahn, “Motor task-to-task transfer learning for motor imagery brain-computer interfaces,” *NeuroImage*, vol. 302, p. 120906, 2024.
- [5] K.-T. Kim, J. Lee, and S. J. Lee, “Convolutional neural network approach for motor imagery and steady-state somatosensory evoked potential-based hybrid brain-computer interface using dry electrodes,” *Biomedical Signal Processing and Control*, vol. 110, p. 108343, 2025.
- [6] Y. Narayan, D. Gautam, R. Kakkar, and D. Lakhwani, “BCI-based EEG signals classification using machine learning approach,” in *Proc. IEEE IATMSI*, 2025.
- [7] K. R. Dharmendra, D. K. Verma, and S. Vats, “Advancing brain-computer interfaces: A deep learning approach for enhanced neural signal processing,” in *Proc. IEEE AUTOCOM*, 2025.
- [8] Z. Zhang *et al.*, “Convolutional dynamically convergent differential neural network for brain signal classification,” *IEEE Trans. Neural Networks and Learning Systems*, vol. 36, no. 5, pp. 8166–8174, 2025.

- [9] J. Wang, L. Yao, and Y. Wang, “Enhanced online continuous brain-control by deep learning-based EEG decoding,” *IEEE Trans. Neural Systems and Rehabilitation Engineering*, vol. 33, pp. 2834–2843, 2025.